

Линейная зависимость

2026

ИСТОЧНИК

“Accuracy on the Line: On the Strong Correlation Between Out-of-Distribution and In-Distribution Generalization”

by J. Miller et al.

@ ICML 2021


<https://arxiv.org/abs/2107.04649>

Воспроизведение датасетов


2018 “Do CIFAR-10 Classifiers Generalize to CIFAR-10?” by B. Rech et al.

CIFAR-10.1: падение точности моделей на 4-10%

(проверяли готовые модели из `hysts/pytorch_image_classification`, `tensorflow/models`)



(a) Test Set A



(b) Test Set B

Воспроизведение датасетов

2019 “Do ImageNet Classifiers Generalize to ImageNet?” by B. Recht et al.


CIFAR-10.1: падение точности моделей на 3-15%

ImageNetv2: падение точности моделей на 11-14%

Не удивительно: черри-пикинг моделей оверфиттит



n07745940 (949)



n07749582 (951)



n01749939 (64)



n01677366 (39)



n02788148 (421)



n02423022 (353)



n02692877 (405)





n02490219 (377)



n03443371 (572)

Феномен линейной зависимости точности

Обнаружен феномен линейной зависимости точности на оригинальном и новом наборе данных




--- Ideal reproducibility

● Model accuracy

— Linear fit

Текстовые данные

Аналогичный феномен на текстовых данных:
2020 “The Effect of Natural Distribution Shift on
Question Answering Models “ by J. Miller et al.




Верхние оценки

Существующие оценки на изменение метрики при сдвиге данных это не объясняют:

$$|\text{acc}_D(f) - \text{acc}_{D'}(f)| \leq d(D, D')$$


Обозначения:

- D - оригинальное распределение
- D' - со сдвигом
- f - модель
- d - расстояние между распределениями




Где наблюдается?

1. на разных датасетах
 - а. домены
 - б. задачи
 - с. метрики
2. на разных моделях
3. на разных гиперпараметрах обучения



Отступление про графики



Чтобы перевести прямые из ограниченного интервала $[0, 1]$ на бесконечность, используют probit преобразование масштаба осей (обратная функция к CDF $N(0, 1)$)


R^2 - Коэффициент детерминации [модели зависимости случайной величины y от факторов x определяется следующим образом] - это доля дисперсии зависимой переменной, объясняемая рассматриваемой моделью зависимости, то есть объясняющими переменными.

[wiki](#)

$$R^2 = 1 - \frac{D[y|x]}{D[y]}$$

Где наблюдается: датасеты

- Image Classification Benchmarks:
 - CIFAR-10 -> CIFAR-10.1, CIFAR-10.2, CINIC-10, STL-10
 - CIFAR-10 -> CIFAR-10-C [C = corruptions] (на большинстве искажений)
 - ImageNet -> ImageNet-V2
 - ImageNet -> ImageNet-C
- Synthetic Pose Estimation:
 - YCB-Objects (рендеринг с разным освещением и текстурой)
- Real-World "Wild" Distribution Shifts (from WILDS):
 - FMoW-WILDS (satellite imagery за разные годы)
 - iWildCam-WILDS (фотоловушки с разных локаций/дат)



Важно: разные метрики (accuracy, F1)

Где наблюдается: модели


- DL

- CNNs
- ViTs

- classical


- логистическая регрессия
- kNNs
- SVMs
- random forests
- random features

Важно: свидетельствует об отсутствии связи феномена с DL / representation learning



Где наблюдается: гиперпараметры

- размер модели (width, depth)
- коэф-ты регуляризации (weight decay, dropout)
- ГП оптимизации (learning rate, optimizer)
- кол-во эпох (проверяли на разных эпохах обучения, в т.ч. эффект early stopping)
- размер обучающей выборки (обучали на случайном подмножестве 1-80%)



Влияние других данных

Вопрос: Как претренин на другом датасете влияет?

Мотивация: ожидается, что претренин на других данных может увеличивать робастность

Факты:

- ImageNet -> Cifar10, FMoW (satellite) – никак
- ImageNet -> фотоловушки – меняет тренд

Объяснение: претренин меняет тренд, если он обучает чему-то новому и полезному (viewpoint invariance для фотоловушек)




Есть не везде!

Не наблюдается на сдвигах:

- Camelyon17-WILDS (гистология из разных больниц)
предположительно из-за дубликатов
- Cifar10 -> Cifar10-C с гауссовым шумом
предположительно из-за изменения ковариаций входного сигнала

Больше статей про нарушения:


- [ID and OOD Performance Are Sometimes Inversely Correlated on Real-world Datasets](#)
- [Accuracy on the wrong line: On the pitfalls of noisy data for out-of-distribution generalisation | OpenReview](#)



Исправление гауссового шума

Добавление шума с разными ковариациями:

- isotropic noise -> слабый линейный тренд
- ковариации соответствуют ID данным -> значительно сильнее



Практическая польза

Директива: чтобы улучшить OOD перформанс – выбирайте модель с лучшим ID перформансом.

Важно отметить: директива противоречит расхожему мнению о трейд-оффе между точностью и робастностью (следующему из оверфиттинга).

ИСТОЧНИК

“Agreement-on-the-Line: Predicting the Performance of Neural Networks under Distribution Shift”

by C. Baek et al.

@NeurIPS 2022

<https://arxiv.org/abs/2206.13089>

Феномен линейной зависимости согласия


Феномен: согласие пар классификаторов на ID и OOD данных подчиняется линейному тренду

Для нейронок:

1. сильная корреляция точности ($\geq 0.95 R^2$) $\Rightarrow$ сильная корреляция согласия
2. причем у них очень близкие slope & bias
3. слабая корреляция точности ($\leq 0.75 R^2$) $\Rightarrow$ слабая корреляция согласия

Для других моделей:

- 1 и 3 чаще всего верно
- 2 – менее строго



Где наблюдается

Пробовали

- разные датасеты
- разные модели
- разное количество эпох

Другие гиперпараметры особо не варьировали

Практическая польза

Польза: Можно использовать для надежной оценки ООД перформанса нейронок без доступа к разметке ООД данных.

Алгоритм:

1. проверяем что agreement корреляция высокая
2. если да,
 - a. знаем, что accuracy корреляция тоже высокая.
причем на примерно той же прямой
 - b. считаем k , b по agreement
 - c. получаем $\text{OOD acc} = k * \text{ID acc} + b$

Надежность: можем определить по величине agreement корреляции

Даже если она не оч высокая (и надежность тоже), такая оценка лучше

Тоу-модель для точности

Ассурасу-on-the-line предлагают рассмотреть тоу-модель, которая

- была бы очень простой
- демонстрировала феномен ассурасу линейной зависимости.

Важно: эта модель не объясняет феномен на сложных данных (типа Cifar10).

Описание модели

Основное распределение

$$y \sim U\{-1, 1\}$$

$$x|y \sim \mathcal{N}(\mu y, \sigma^2 I_{d \times d})$$

Сдвиг: $\mu' = \alpha\mu + \beta\Delta$, $\sigma' = \gamma\sigma$

$$\alpha, \beta, \gamma > 0$$

$$\Delta \sim U(S^{d-1})$$

Рассматриваем линейные классификаторы: $x \mapsto \text{sign}(\theta^T x)$

Th. С вероятностью $(1-\delta)$ разница probit точностей лежит на тренде α/γ :

$$\left| \Phi^{-1}(\text{acc}_{D'}(\boldsymbol{\theta})) - \frac{\alpha}{\gamma} \Phi^{-1}(\text{acc}_D(\boldsymbol{\theta})) \right| \leq \frac{\beta}{\gamma\sigma} \sqrt{\frac{2 \log 2/\delta}{d}}$$

Модель нарушений при аддитивном гауссовом шуме

Основное распределение: $\mathbf{x}|y \sim \mathcal{N}(\boldsymbol{\mu} \cdot y; \Sigma)$

Сдвиг: $\Sigma' = \Sigma + (\sigma')^2 I_{d \times d}$

Для константности соотношения пробитов точностей необходимо чтобы не зависело от θ – возможно только при $\Sigma = I$

$$\frac{\boldsymbol{\theta}^\top \Sigma' \boldsymbol{\theta}}{\boldsymbol{\theta}^\top \Sigma \boldsymbol{\theta}} = 1 + \frac{\sigma'^2 \|\boldsymbol{\theta}\|^2}{\boldsymbol{\theta}^\top \Sigma \boldsymbol{\theta}}$$

Если $\Sigma \neq I$ – линейного тренда не будет

Косвенно подтверждается экспериментами на Cifar10-C с гауссовым шумом

Модель для согласия

С помощью похожей модели продемонстрировали линейный тренд согласия в статье

“Theory of Agreement-on-the-Line in Linear Models and Gaussian Data”

by C. Baek et al.

@AISTATS2025

<https://proceedings.mlr.press/v258/baek25a.html>

Модель из статьи Do ImageNet...

Модель j -> скилл s_j (это число)

Изображение i -> сложность τ_i -> модель не ошибается с вероятностью $\Phi(s_j - \tau_i)$

Пусть τ всех изображений распределено нормально $\tau \sim \mathcal{N}(\mu, \sigma)$

Тогда точность модели
$$\mathbb{E}_{\tau \sim \mathcal{N}(\mu, \sigma)} [\Phi(s - \tau)] = \Phi\left(\frac{s - \mu}{\sqrt{\sigma^2 + 1}}\right)$$

Пробит - выражение в скобках

Далее рассматриваем 2 распределения: $\mathcal{N}(\mu_1, \sigma_1)$, $\mathcal{N}(\mu_2, \sigma_2)$

и получаем линейный тренд

Важно: эта модель не обладает предиктивной способностью (не позволяет предсказать, будет ли линейный тренд на конкретном сдвиге распределений)

